TED [Together]

Share, learn, discuss.

```
## READ WATCH_NEXT DATASET

watch_next_dataset_path = "s3://mz-unibg-data-tcm2021/watch_next_dataset.csv"

watch_next_dataset = spark.read.option("header","true").csv(watch_next_dataset_path)

# CREATE THE AGGREGATE MODEL, ADD WATCH_NEXT TO TEDX_DATASET

watch_next_dataset_agg = watch_next_dataset.groupBy(col("idx").alias("idx_ref")).agg(collect_list("watch_next_idx").alias("watch_next_idxs"))

#watch_next_dataset_agg.printSchema()

tedx_dataset_final = tedx_dataset_agg.join(watch_next_dataset_agg, tedx_dataset_agg.id == watch_next_dataset_agg.idx_ref, "left") \
    .drop("idx_ref") \
    .select(col("_id"), col("*"))
```


Abbiamo esteso il job PySpark "*CreateDataLake*" per aggiungere la lista degli ID dei talk "watch next" ad ogni video nella collection "*tedx_video_data*" di MongoDB.

Dati trattati:

- tedx_dataset.csv
- watch_next_dataset.csv

> Watch Next: modello E/R e risultato

TED[Together]



```
id: "8d2005ec35280deb6a438dc87b225f89"
  main speaker: "Alexandra Auer"
  title: "The intangible effects of walls"
  details: "More barriers exist now than at the end of World War II, says designer..."
  posted: "Posted Apr 2020"
  url: "https://www.ted.com/talks/alexandra auer the intangible effects of wal..."
> tags: Array
~ watch next idxs: Array
    0: "5bd34fcc55d9e1267f605fa0c060d54e"
     1: "5bd34fcc55d9e1267f605fa0c060d54e"
    2: "9f7b1654e792011b7e1c6f4288520226"
    3: "fe35edd737282ab3a325f2387cf1b50b"
    4: "fe35edd737282ab3a325f2387cf1b50b"
     5: "9f7b1654e792011b7e1c6f4288520226"
     6: "d9896b41b372ec60cdd3c662e57caad3"
     7: "d9896b41b372ec60cdd3c662e57caad3"
    8: "9f7h1654e792011h7e1c6f4288520226"
     9: "5134ae81a27c94354173f38e84289ad5"
     10: "5134ae81a27c94354173f38e84289ad5"
    11: "9f7b1654e792011b7e1c6f4288520226"
     12: "8576654442b6633b1dc0eb48a989172a"
     13: "8576654442b6633b1dc@eb48a989172a"
     14: "9f7b1654e792011b7e1c6f4288520226"
     15: "078766d6cc461cf71d45dc268b66db95"
     16: "078766d6cc461cf71d45dc268b66db95"
     17: "9f7b1654e792011b7e1c6f4288520226"
```

TED[Together]


> AWS Glue - GetTagDescription

Il nuovo job PySpark "GetTagDescription" ci permette di creare una nuova collection in MongoDB ("tedx_tag_data") che associa ad ogni tag una breve descrizione del suo significato estratta da Wikipedia e la lista degli ID dei talks che usano quel tag.

```
tags_dataset_path = "s3://mz-unibg-data-tcm2021/tags_dataset.csv"
tags_dataset = spark.read.option("header", "true").csv(tags_dataset_path)
print("tags_dataset ready!\n")
tag_description_dataset_path = "s3://mz-unibg-data-tcm2021/tag_description_dataset.csv"
tag_description_dataset = spark.read.option("header", "true").csv(tag_description_dataset_path)
tag description dataset = tag description dataset.groupBy(col("tag").alias("tag ref")).agg(first("description").alias("description"))
print("tag_description_dataset ready!\n")
# CREATE THE AGGREGATE MODEL, ADD TAGS TO TEDX DATASET
tags_dataset_agg = tags_dataset.groupBy(col("tag")).agg(collect_list("idx").alias("idxs"))
print("tags_dataset_agg ready!\n")
tags dataset final = tags dataset agg.join(tag description dataset, tags dataset agg.tag == tag description dataset.tag ref, "left") \
    .drop("tag ref") \
    .select(col("tag"), col("*"))
```

> GetTagDescription: modello E/R e risultato

TED[Together]



```
id: ObjectId("60a2ccfe25167721d06ed983")
 tag: "crowdsourcing"
vidxs: Array
    0: "76acb47b8da0314196ef7985500b8f52"
    1: "1f43ebbd6d5f2284d38aceb18e4f701a"
    2: "309945f52273c5a157020e0613cd637f"
    3: "3015b593bf0b568ab4b486df8d31c9be"
    4: "1c4c031d8c45d543da84b22337cabff6"
    5: "f600dfe87de34c1034b602480af6404e"
    6: "86fdde954c266abb824ea9c3d3d9cae0"
    7: "0e9e1ae2484bfd687a597fe22cc20a7f"
    8: "f761dc1f0293c2ed7ddf95f6add11646"
    9: "02a9e121ff52aa0a7192fa8689a14c5a"
    10: "06e3134ec06f6e4628d2558af114be29"
    11: "12072cf21860342ace16f12d1a56eeea"
    12: "5f29ec60adfa33e4602bf0bd7f639291"
 description: "Crowdsourcing is a sourcing ...
```

- Incongruenza dei dataset:
 - ricalcolo dopo aggiornamento dei tag
 - alcuni tag potrebbero non avere una descrizione
- bisogna controllare che le descrizioni dei tag corrispondano effettivamente all'argomento trattato.

> Possibili sviluppi

- Estendere le descrizioni anche agli autori (main speaker)
- ricerca dei tag correlati
- migliorare l'algoritmo di acquisizione delle descrizioni
- creare una Lambda function che permetta di aggiornare in automatico le descrizioni dei tag anche al variare del dataset